

Predictions for the Next Phase of AI

Henrique, Johann e Vítor

Pontos Chave da Apresentação - Noam Shazeer

- > O que as LLMs querem de um perspectiva de software
- > Trajetória do Noam Shazeer
- > Como hardware pode beneficiar o treinamento de LLMs

O que as LLMs querem de um perspectiva de software

- Poder computacional
- Parâmetros
- Profundidade (n° de camadas)
- Não Linearidade?
- Fluxo de informação (em sequência, em profundidade, etc)
- Dados de treino (únicos)

Pontos positivos de trabalhar com modelos de linguagem



- Texto é o jeito mais completo de treinar um modelo
- Definir problemas é simples:
 - “Produza a distribuição de probabilidade do próximo token”
- Dados de treino abundantes

2016: Sparsely-Gated Mixture of Experts (MoE)

Mais parâmetros

Sem precisar de mais poder computacional

Roda na velocidade da multiplicação de matrizes




2017: Transformers (self-attention)


Melhor sequencialização do fluxo de dados

Roda na velocidade da multiplicação de matrizes

Scaled Dot-Product Attention



Multi-Head Attention



2018: Supercomputadores + SPMD -> LLMs

single program, multiple data

Modelo baseado
em paralelismo



Mesh-TensorFlow: Deep Learning for Supercomputers

Noam Shazeer, Youlong Cheng, Niki Parmar,
Dustin Tran, Ashish Vaswani, Penporn Koanantakool, Peter Hawkins, HyoukJoong Lee
Mingsheng Hong, Cliff Young, Ryan Sepassi, Blake Hechtman
Google Brain
{noam, ylc, nikip, trandustin, avaswani, penporn, phawkins,
hyouklee, hongm, cliffy, rsepassi, blakehechtman}@google.com

Flashback pra 2018

“Abraham Lincoln” (para um modelo com 33 milhões de parâmetros)

Abraham Lincoln was an American voodoo activist and former alcoholic who liked to have been the chief for a heroic, misguided he attended—never to represent him. He was later noted as, "one of the most triumphal scholars of the 20th century."

Lincoln's essay "Crypt of the Dark", titled "Prospecting his. The participation of icons in fusion with modern regime, is neglect", was published in 1976. Over the course of his life, Lincoln lived. Ford, who was a Loyalist, was a translator of Russian Orthodox Jewish sources, his book "Ami el repertory" which began in substitution in the 1950s.

Flashback pra 2018

“Abraham Lincoln” (para um modelo com 5 bilhões de parâmetros)

Abraham Lincoln (March 1, 1809{{spaced ndash}}March 15, 1865) was an American lawyer, jurist, and politician. He served as the 19th President of the United States, from March 1861 until his assassination in April 1865.

Por que treinar modelos de linguagem pequenos?

- Generalização
- Velocidade
- Memória

Apenas não faça

- ~~Generalização~~

O banco de dados de treinamento é muito pequeno

- ~~Velocidade~~

O computador é muito lento

- ~~Memória~~

Mesh-TensorFlow não foi usado

O que as LLMs querem do Hardware

- PFLOPs
 - Capacidade de Memória (todos os níveis da hierarquia)
 - Largura de Banda da Memória (todos os níveis da hierarquia)
 - Largura de Banda da Rede (todos os níveis da hierarquia)
-
- Pouca precisão - na maioria das vezes é ok
 - Determinismo - muito bom de ter